

E07 — Documentación técnica Sprint 4

Integración, refinamiento y cierre del sistema agrovoltaico dinámico

Proyecto:	PIA — Sistemas Agrovoltaicos Dinámicos
Equipo:	Chacorocalfarobar
Sprint:	4 de 4
Entregable:	E07
Fecha:	11 de mayo de 2026

Resumen

Este documento recoge la base técnica del Sprint 4, centrada en cerrar la integración del sistema, corregir problemas detectados en el Sprint 3 y documentar la evolución del dashboard y de los modelos. El Sprint 3 entregó un dashboard funcional v1 orientado a visualización, series temporales, recomendación de rotación y alertas. En el Sprint 4 se ha ampliado el backend para soportar una formulación más realista del problema como sistema de decisión secuencial: simulación de riego, reconstrucción de humedad y temperatura del suelo, definición de reglas agronómicas por cultivo, generación de políticas de control mediante RL offline y entrenamiento de un modelo temporal LSTM como aproximador del modelo del mundo.

El resultado actual es una arquitectura técnicamente más completa: el dashboard estable se mantiene operativo, mientras que el backend incorpora los componentes necesarios para simular políticas de rotación e irrigación. La integración visual completa de la nueva pestaña agronómica queda preparada a nivel de código, pero se mantiene desacoplada del dashboard principal hasta validar la experiencia de usuario y evitar regresiones de carga.

1. Contexto del Sprint 4

1.1 Objetivo del sprint

Según la planificación del proyecto, el Sprint 4 corresponde a la fase de integración, refinamiento y entrega final. Los entregables técnicos principales asociados son:

- **Eo6:** dashboard v2 final con recomendaciones.
- **Eo7:** documentación técnica completa.
- **Eo8:** presentación final al cliente.
- **Eo9:** documentación de gestión acumulativa.

El objetivo técnico del sprint no es únicamente añadir más visualizaciones, sino cerrar una versión coherente del sistema de soporte a la decisión. En los sprints anteriores el foco estuvo en entender los datos, construir una política inicial de rotación y preparar un dashboard funcional. En este sprint se revisa el planteamiento completo para acercarlo al problema real: optimizar un sistema agrovoltáico dinámico en el que las decisiones de rotación de placas afectan simultáneamente a la producción energética y al estado agronómico del cultivo.

1.2 Limitación principal detectada

Durante la revisión del Sprint 3 se identificó un problema de base: el dataset disponible no contiene datos reales de riego. Además, las lecturas de humedad y temperatura del suelo son escasas temporalmente, con registros aproximadamente cada 6 horas. Esto limita mucho la posibilidad de entrenar directamente un modelo que aprenda la respuesta del suelo ante acciones de riego o rotación de paneles.

La consecuencia es importante: no se puede plantear un modelo de control de riego puramente supervisado si no existen ejemplos reales de cuándo se regó, cuánto se regó y cómo respondió el suelo. Por tanto, el Sprint 4 adopta una estrategia de simulación justificada:

- Se utilizan los rangos observados de humedad y temperatura como límites realistas de trabajo.
- Se simulan escenarios de riego con distintas frecuencias y dosis.
- Se reconstruye una dinámica plausible de humedad y temperatura del suelo.

- Se generan trayectorias artificiales pero consistentes para entrenar modelos temporales.
- Se separa claramente lo observado, lo simulado y lo aprendido por modelos.

Esta decisión permite avanzar hacia una arquitectura de RL sin ocultar la incertidumbre de los datos. El sistema no afirma disponer de riesgo real medido; lo simula bajo hipótesis documentadas para poder evaluar políticas.

2. Punto de partida: Sprint 3

2.1 Dashboard v1

El informe del dashboard entregado en Sprint 3 documenta la versión v1 funcional. La aplicación principal estaba organizada en cuatro vistas:

- **Dashboard:** métricas operativas, indicadores de estado y visión general.
- **Series temporales:** exploración temporal de variables de sensores y producción.
- **Recomendación:** recomendación de ángulo de rotación a partir de la lógica existente.
- **Alertas:** identificación de situaciones críticas mediante umbrales.

El dashboard v1 fue un hito útil porque transformó el análisis previo en una herramienta navegable. Sin embargo, todavía estaba muy ligado a reglas e índices agregados, especialmente el IEC, y no incorporaba una simulación explícita de acciones futuras ni una formulación completa de MDP.

2.2 Limitaciones funcionales de la versión anterior

Las principales limitaciones detectadas antes del Sprint 4 fueron:

- La recomendación de rotación no estaba plenamente conectada con una función de recompensa multiobjetivo.
- El riego no aparecía como variable de decisión, debido a la ausencia de datos reales.
- La humedad del suelo aparecía interpolada y poco dinámica, por lo que no era suficiente para aprender necesidades hídricas.
- El dashboard mostraba resultados, pero no simulaba trayectorias futuras bajo distintas políticas.
- No existía todavía un modelo temporal entrenado para aproximar transiciones del sistema.
- Las diferencias entre zonas con placas y sin placas no estaban incorporadas como parte explícita del modelo.

El Sprint 4 parte de estas limitaciones y reorganiza el backend para preparar una versión más cercana a un sistema de decisión secuencial.

3. Cambios principales respecto al Sprint 3

La siguiente tabla resume los cambios más relevantes introducidos en el Sprint 4.

Área	Cambio realizado
Datos de riego	Se ha creado una simulación de riego al no existir mediciones reales. Se generan escenarios con diferentes intervalos, dosis y ruido controlado.
Humedad y temperatura del suelo	Se reconstruye la evolución de VWC y temperatura del suelo a resolución de 10 minutos, usando variables ambientales, riego simulado, lluvia y diferencias entre zona con placas y zona de referencia.
MDP	Se ha separado el estado del sistema en variables exógenas, acciones controlables y variables endógenas que se deben predecir. Esto permite formular el problema como modelo del mundo.
Política RL	Se ha añadido una política offline que combina componente agronómica y energética mediante una recompensa ponderada. La acción incluye rotación de placas y riego.
Cultivos	Se han incorporado perfiles agronómicos por cultivo, con rangos favorables, riesgos y calendario de crecimiento.
Zonas	Se estructura el análisis para diferenciar zonas, especialmente R1 como referencia a pleno sol y S1 como zona bajo influencia de placas.
Modelo temporal	Se ha entrenado un LSTM para predecir el siguiente estado endógeno a partir de una ventana temporal de contexto.
Dashboard	Se mantiene estable el dashboard principal de cuatro pestañas. Se prepara una pestaña agronómica nueva, pero queda desacoplada hasta cerrar su integración visual sin regresiones.
Reproducibilidad	Se han separado los CSV grandes del repositorio y se han documentado los pasos para regenerarlos localmente.

4. Arquitectura técnica actual

4.1 Visión general

La arquitectura actual se divide en cuatro capas:

1. **Capa de datos:** notebooks y scripts que generan datasets limpios, datasets simulados y datasets de entrenamiento.
2. **Capa de modelo del mundo:** definición de estados, acciones, variables objetivo y transiciones.
3. **Capa de decisión:** reglas agronómicas, política RL offline y cálculo de recompensa multiobjetivo.
4. **Capa de presentación:** dashboard Streamlit, actualmente estable en la versión v1 ampliada a nivel backend.

La decisión de mantener desacoplada la integración visual más ambiciosa responde a un criterio de estabilidad. Durante el sprint se probó una ampliación del frontend con una quinta pestaña de agronomía, pero provocó problemas de carga en el dashboard principal. Por ello se recuperó el dashboard estable y se dejó el trabajo agronómico como backend preparado, no como vista final conectada.

4.2 Ficheros principales

Tabla 1. Ficheros principales del Sprint 4 y su función técnica

Fichero	Función técnica
sprint3/Master_dataset_reg.ipynb	Notebook de generación de datos simulados de riego, humedad y temperatura del suelo.
sprint3/world_model_dataset.py	Define columnas exógenas, acciones, variables endógenas y construcción del dataset de transiciones.
sprint3/build_world_model_training_dataset.py	Script reproducible para generar el dataset final de entrenamiento del modelo del mundo.
sprint3/agricultural_rules.py	Reglas agronómicas por cultivo, etapa, zona y tipo de riesgo.
sprint3/rl_policy.py	Construcción de política RL offline y trayectorias con recompensa agronómica y energética.
sprint3/ten_min_pipeline.py	Pipeline a resolución de 10 minutos para derivar variables agronómicas y de decisión.
sprint3/world_model_lstm.py	Arquitectura PyTorch del LSTM.
sprint3/world_model_lstm_dataset.py	Ventanas temporales, escalado y partición cronológica del dataset.
sprint3/world_model_lstm_training.py	Entrenamiento, métricas, predicción y guardado de artefactos.
sprint3/train_world_model_lstm.py	CLI para entrenar el LSTM de forma reproducible.
sprint3/world_model_lstm_inference.py	API de inferencia para predecir el siguiente estado.
sprint3/world_model_rollout.py	Simulación de rollouts multi-step bajo una secuencia de acciones.
sprint3/dashboard_lstm.py	Adaptador para integrar predicciones LSTM en el dashboard en una fase posterior.
sprint3/data_loader.py	Carga centralizada de datasets, métricas, estado del modelo y artefactos.
sprint3/tabs/tab_agronomia.py	Vista agronómica preparada, actualmente no conectada al dashboard principal.

5. Simulación de riego, humedad y temperatura del suelo

5.1 Motivación

El modelo necesitaba una variable de riego para poder evaluar políticas que incluyan decisiones hídricas. Sin embargo, el dataset original no proporciona registros de activación de riego ni dosis aplicadas. La solución adoptada consiste en simular el riego como una variable de acción controlable, generando distintos escenarios plausibles.

Esta simulación no pretende sustituir una medición real, sino crear un entorno de entrenamiento razonable para:

- analizar cómo se comportaría el sistema ante diferentes estrategias de riego;
- entrenar un modelo temporal capaz de aprender transiciones;
- permitir rollouts de políticas futuras;
- hacer explícitas las hipótesis utilizadas.

5.2 Resolución temporal

El sistema trabaja con resolución de 10 minutos. Esta resolución es más fina que las lecturas originales de humedad, que se encuentran alrededor de 6 horas, pero es necesaria para simular acciones de control y trayectorias. A nivel de modelización, se acepta que las lecturas originales no bastan para observar todas las dinámicas reales, por lo que se genera una señal continua mediante una dinámica parametrizada.

5.3 Escenarios de riego

Se generan escenarios combinando distintos intervalos y dosis:

- **Intervalos de riego:** 4 h, 6 h, 8 h y 12 h.
- **Dosis nominales:** 1 mm, 2 mm y 3 mm.
- **Ruido temporal:** desplazamiento aleatorio controlado alrededor del instante previsto.
- **Ruido de dosis:** variación moderada alrededor de la dosis nominal.

Esto produce 12 políticas base de riego. Cada política genera una trayectoria distinta del mismo periodo temporal. El objetivo no es escoger todavía la política óptima, sino enriquecer el espacio de entrenamiento para que el modelo temporal observe respuestas diferentes del suelo.

5.4 Dinámica de humedad

La humedad volumétrica del suelo se representa mediante la variable VWC. La simulación incorpora tres efectos principales:

- **Entrada de agua:** aumento de VWC cuando hay riego o precipitación.
- **Evapotranspiración:** pérdida de humedad asociada a radiación, temperatura, viento y condiciones ambientales.
- **Drenaje:** reducción progresiva cuando la humedad supera niveles de equilibrio.

En la calibración actual se han usado parámetros diferenciados entre zona de referencia y zona bajo placas:

Tabla 2. Parámetros de calibración de la dinámica de humedad por zona

Parámetro	Zona R1	Zona S1
Coefficiente de entrada de agua	0.0100	0.0110
Coefficiente de evapotranspiración	0.10	0.085

Parámetro	Zona R1	Zona S1
Coefficiente de drenaje	0.05	0.05
Evapotranspiración base	0.006	0.006

Estos valores se calibraron para que la señal simulada se mantuviera dentro de rangos plausibles. La diferencia entre R1 y S1 refleja la hipótesis de que la zona bajo placas puede conservar algo más de humedad al recibir menos radiación directa.

5.5 Dinámica de temperatura del suelo

La temperatura del suelo se simula como una variable influida por:

- temperatura del aire;
- radiación solar;
- cobertura o sombreado por placas;
- humedad del suelo;
- ciclo diario.

La zona S1 se modela como una desviación respecto a R1, lo que permite capturar el efecto de las placas sin duplicar completamente el modelo. Esta decisión reduce colinealidad y mantiene una estructura más interpretable: R1 funciona como referencia a pleno sol y S1 como zona influida por el sistema agrovoltaico.

5.6 Corrección del identificador de episodio

Durante la revisión se detectó que el notebook podía generar un número de filas superior al esperado. El origen estaba relacionado con la creación de identificadores de episodio y la combinación de trayectorias simuladas. Se corrigió el cálculo del identificador temporal usando una conversión explícita del índice temporal a segundos:

```
proxy.index.to_numpy(dtype="datetime64[ns]").astype("int64") // 10**9
```

Con esta corrección se evitan colisiones y duplicidades no deseadas en la generación de episodios. El dataset final puede seguir siendo mayor que el master dataset original, pero ahora por una razón esperada: se multiplican trayectorias al generar varios escenarios de riego.

6. Formulación como MDP y modelo del mundo

6.1 Motivación del MDP

El problema agrovoltaico es secuencial. La decisión de rotar una placa o activar el riego no afecta solamente al instante actual, sino también al estado futuro del cultivo y a la producción energética. Por este motivo, en Sprint 4 se reformula el sistema como un MDP.

La formulación conceptual es:

- **Estado:** condiciones ambientales, solares, energéticas y agronómicas actuales.
- **Acción:** ángulo de las placas y decisión de riego.
- **Transición:** evolución del sistema al siguiente paso temporal.
- **Recompensa:** combinación de calidad agronómica y producción energética.

6.2 Separación de variables

El fichero `sprint3/world_model_dataset.py` formaliza la separación de variables:

Tabla 3. Separación de variables del modelo del mundo

Grupo	Descripción
Variables exógenas	Variables que el agente no controla directamente, como hora, día, posición solar, radiación despejada, temperatura del aire, viento, precipitación o PAR de referencia.
Acciones	Variables controlables: ángulo de seguimiento, activación de riego y dosis de riego.
Variables endógenas	Variables que el sistema debe predecir: irradiancia sobre plano, albedo, diferencia de PAR, VWC simulada, temperatura del suelo y deltas entre zonas.
Estado determinista	Variables que no conviene aprender con un LSTM porque se calculan mejor por regla, como los minutos desde el último riego (<code>minutes_since_last_irr</code>).

Esta separación es importante porque evita pedir al LSTM que aprenda variables que tienen una actualización exacta. En concreto, `minutes_since_last_irr` se retiró de los targets aprendidos y se recalcula de forma determinista.

6.3 Dataset de transiciones

A partir del dataset simulado se construye un dataset de transiciones. Cada fila representa un paso de 10 minutos: $(s_t, a_t) \rightarrow s_{t+1}$. El script `sprint3/build_world_model_training_dataset.py` genera el CSV final de entrenamiento. Este archivo no se versiona en Git por tamaño, pero es reproducible desde los notebooks y scripts del repositorio.

7. Reglas agronómicas y cultivos

7.1 Necesidad de reglas por cultivo

La componente agrícola de la recompensa no puede evaluarse con un único umbral genérico. Cultivos distintos toleran rangos distintos de humedad, temperatura y radiación. Además, una misma especie puede requerir condiciones diferentes según la etapa de crecimiento.

Por este motivo se incorporan perfiles agronómicos en `sprint3/agricultural_rules.py`. La idea es que el sistema pueda evaluar si una zona está en condiciones favorables para un cultivo concreto y no únicamente si una variable supera un umbral fijo.

7.2 Información agronómica incorporada

El backend permite representar:

- cultivo seleccionado;
- zona analizada;
- rangos favorables de VWC;
- rangos favorables de temperatura del suelo;
- rangos de radiación o PAR;
- riesgos por déficit o exceso de agua;
- estrés térmico por calor o frío;
- exceso de radiación;
- calendario o etapas de crecimiento.

Estos perfiles permiten que la evaluación agronómica sea interpretable. En lugar de decir únicamente que una acción tiene mejor recompensa, el sistema puede explicar si la mejora proviene de evitar déficit hídrico, exceso térmico o falta de radiación.

7.3 Zonas del sistema

La implementación diferencia zonas, especialmente:

- **R1:** zona de referencia o zona con mayor exposición solar.
- **S1:** zona bajo influencia de las placas.

La zona S2 se puede tratar posteriormente con la misma lógica, pero en esta fase se prioriza una formulación clara R1-S1 para evitar redundancias y colinealidad excesiva. A nivel de dashboard, el selector de zona está preparado en la pestaña agronómica, aunque dicha pestaña todavía no forma parte de la navegación principal estable.

8. Política RL offline basada en DQN

8.1 Por qué RL offline

En este proyecto no se dispone de un entorno real donde probar acciones de control de forma libre y repetida. Además, no sería responsable activar rotaciones de placas o decisiones de riego reales sin una fase previa de validación. Por este motivo, el Sprint 4 plantea una política de aprendizaje por refuerzo *offline*.

La política se entrena a partir de datos históricos y simulados del sistema agrovoltaico. A partir de estos datos se construyen estados, acciones candidatas y una recompensa multiobjetivo que combina el rendimiento energético con el estado agronómico del cultivo. Sobre esta base se entrena una aproximación tipo Deep Q-Network (DQN), que estima el valor esperado de cada acción en una situación determinada.

Esta política no debe interpretarse como un agente desplegado directamente en producción, sino como un primer módulo de decisión automática que permite:

- comparar acciones candidatas;
- estudiar el compromiso entre energía, cultivo y riego;
- generar recomendaciones interpretables;
- evaluar la utilidad de una política DQN antes de conectarla a *rollouts* con el *World Model LSTM*.
-

8.2 Espacio de acciones

El espacio de acciones se define como una acción conjunta factorizada en dos dimensiones principales:

- acción energética: orientación o ángulo recomendado para las placas;
- acción hídrica/agronómica: decisión de riego, dosis y acción de manejo del cultivo.

Esta factorización permite que el sistema no trate la orientación de placas y el riego como decisiones independientes sin relación, sino como una combinación de control que afecta simultáneamente a la producción energética y al estado del cultivo.

En la implementación actual, el agente no genera acciones continuas arbitrarias. En su lugar, evalúa un conjunto de acciones candidatas observadas o derivadas del *dataset*, y selecciona aquella con mayor valor Q estimado para el estado actual.

8.3 Recompensa multiobjetivo

La recompensa se define como una combinación ponderada entre componente agronómica y componente energética, con penalización por daño crítico:

$$R = \alpha \cdot R_{\text{agro}} + \beta \cdot R_{\text{energia}} - P_{\text{riesgo}}$$

donde:

- R_{agro} mide el grado de adecuación agronómica del estado del cultivo;
- R_{energia} mide la componente asociada a producción energética;
- P_{riesgo} penaliza situaciones críticas para el cultivo;

- α y β controlan el compromiso entre agricultura y energía.

La configuración actual usa:

- $\alpha = 0.45$ para la componente agronómica;
- $\beta = 0.55$ para la componente energética;
- penalización de daño crítico igual a 0.35.

Esta ponderación da algo más de peso a la energía, pero mantiene la agricultura como componente casi equivalente. Esto es coherente con un sistema agrovoltaico: el objetivo no es maximizar únicamente la energía, sino encontrar una política que preserve el estado del cultivo mientras mantiene una producción energética adecuada.

8.4 Política DQN offline

La política actual se basa en una aproximación DQN *offline*. El modelo recibe como entrada variables de estado como hora del día, elevación solar, estado hídrico, temperatura del suelo, radiación, estrés del cultivo, zona agrícola y tipo de cultivo. También incorpora la acción candidata mediante una codificación categórica.

El modelo aprende una función Q que estima el valor esperado de aplicar una acción determinada en un estado concreto. Para cada estado relevante, se generan acciones candidatas y se selecciona la acción con mayor valor Q . Además, se calcula una medida de confianza a partir de la diferencia entre la mejor acción y la segunda mejor alternativa.

Esta aproximación permite obtener una recomendación accionable, pero sigue siendo una política *offline*: no explora directamente en el entorno real y depende de la calidad de los datos y simulaciones disponibles.

8.5 Riesgos penalizados

La política penaliza varios tipos de daño agronómico:

- déficit hídrico;
- exceso de agua;
- estrés por calor;
- estrés por frío;
- exceso de radiación.

Estas penalizaciones actúan como restricciones suaves dentro de la recompensa. Así, una acción que mejore la producción energética puede dejar de ser óptima si incrementa el riesgo de daño para el cultivo.

8.6 Relación con el IEC

En Sprint 3 el IEC tenía un papel más central como índice resumen del equilibrio energía-cultivo. En Sprint 4, al introducir una recompensa RL explícita y una política DQN *offline*, el IEC deja de ser el criterio principal de decisión.

La recomendación técnica es mantener el IEC únicamente como indicador de apoyo o métrica explicativa, pero no como función objetivo principal. La razón es que la recompensa RL permite una formulación más flexible y transparente: separa la componente agrícola, la componente energética, las penalizaciones por riesgo y los pesos de decisión.

Por tanto, el *dashboard* puede conservar indicadores agregados de equilibrio para facilitar la lectura rápida, pero la optimización de la política debe basarse en la recompensa multiobjetivo y en los valores Q estimados por el modelo DQN.

9. Modelo LSTM del mundo

9.1 Objetivo del modelo

El LSTM se entrena como modelo del mundo. Su tarea es predecir el siguiente estado endógeno del sistema a partir de:

- una ventana temporal reciente;
- variables exógenas;
- acciones aplicadas;
- variables endógenas actuales.

El modelo aprende una aproximación de la transición: $\hat{s}_{t+1} = f_{\theta}(s_{t-k:t}, a_{t-k:t}, x_{t-k:t})$, donde k es el tamaño de la ventana temporal. En la configuración actual, $k = 12$, equivalente a 2 horas de contexto con resolución de 10 minutos.

9.2 Por qué LSTM y no Transformer

Se eligió LSTM por tres motivos:

- El volumen de datos reales es limitado, especialmente en humedad y riego.
- La estructura temporal es moderada y no requiere todavía atención de largo alcance.
- El LSTM es más fácil de entrenar, depurar y explicar en una entrega académica.

Un Transformer podría ser interesante en una fase posterior, pero en el estado actual añadiría complejidad sin garantías de mejora. La prioridad del sprint es cerrar una arquitectura reproducible, no maximizar sofisticación.

9.3 Variables de entrada

Las entradas combinan variables exógenas del tiempo y entorno, acciones de control y estado endógeno actual. El tensor final de entrenamiento tiene forma:

$$\mathbf{X} \in \mathbb{R}^{\{76620 \times 12 \times 22\}}$$

Esto significa:

- 76.620 ventanas válidas;
- 12 pasos temporales por ventana;
- 22 variables de entrada por paso.

9.4 Variables objetivo

El modelo predice 7 targets:

- `next_GPOA_mean`
- `next_ALBEDO_mean`
- `next_Delta_PAR_S1`
- `next_VWC_R1_sim`
- `next_Delta_VWC_S1_sim`
- `next_Tsoil_R1_sim`
- `next_Delta_Tsoil_S1_sim`

Inicialmente se intentó predecir también `minutes_since_last_irr`, pero el resultado no era satisfactorio porque esta variable no necesita aprendizaje: se actualiza de forma determinista. Por tanto, se retiró de los targets del LSTM y se calcula mediante regla: si hay riego, el contador vuelve a 0; si no hay riego, aumenta en 10 minutos.

9.5 Arquitectura

La arquitectura implementada en `sprint3/world_model_lstm.py` usa:

- `batch_first=True`; dos capas recurrentes por defecto;
- dropout moderado;
- normalización de la representación final;
- capa lineal de salida para regresión multivariable.

El entrenamiento se gestiona desde `sprint3/train_world_model_lstm.py`, separando la preparación de ventanas, escalado, entrenamiento, métricas y guardado de artefactos.

9.6 Resultados de entrenamiento

El último entrenamiento disponible generó los siguientes valores:

- Filas cargadas: 414.744.
- Filas tras eliminar nulos: 76.764.
- Ventana temporal: 12 pasos.
- Dimensión de entrada: $76.620 \times 12 \times 22$.
- Dimensión de salida: 76.620×7 .
- **Loss final de entrenamiento:** 0.006963.
- **Loss final de validación:** 0.005531.

Tabla 4. Métricas de validación del LSTM del modelo del mundo

Target	MAE	RMSE
next_GPOA_mean	12.740058	26.970427
next_ALBEDO_mean	1.472298	3.020591
next_Delta_PAR_S1	7.606666	14.421614
next_VWC_R1_sim	0.003852	0.005831
next_Delta_VWC_S1_sim	0.000652	0.000932
next_Tsoil_R1_sim	0.111123	0.192392
next_Delta_Tsoil_S1_sim	0.048038	0.109392




Figura 1. Evolución de la pérdida de entrenamiento y validación del LSTM. La curva muestra una reducción progresiva del error y ausencia de divergencia fuerte entre entrenamiento y validación.




Figura 2. Comparación de errores MAE y RMSE por variable objetivo del modelo LSTM. Las variables de humedad y temperatura simuladas presentan errores bajos, mientras que las variables radiativas concentran mayor dificultad.

9.7 Interpretación de resultados

Las métricas son especialmente buenas en humedad y temperatura del suelo simuladas. Esto es esperable porque esas variables proceden de una dinámica parametrizada y no de un sistema físico completamente observado. En irradiancia y PAR los errores son mayores, pero se mantienen razonables para una primera aproximación de modelo del mundo.

El punto más importante no es afirmar que el modelo reproduce perfectamente la realidad, sino que permite simular trayectorias coherentes bajo diferentes acciones. Es una herramienta para análisis de políticas, no todavía un gemelo digital validado con datos reales de riego.

10. Rollouts y simulación de políticas

10.1 Uso previsto

El fichero `sprint3/world_model_rollout.py` permite simular varios pasos hacia adelante aplicando una secuencia de acciones. Esto habilita el siguiente flujo:

5. Tomar una ventana reciente del sistema.
6. Definir una política candidata de rotación y riego.
7. Predecir el siguiente estado con el LSTM.
8. Recalcular variables deterministas.
9. Repetir el proceso para construir una trayectoria futura.
10. Evaluar la recompensa acumulada de la política.

Este flujo es la pieza que conecta el modelo temporal con la toma de decisiones. En una fase final, el dashboard podría permitir comparar varias políticas candidatas y mostrar cuál ofrece mejor equilibrio energía-cultivo.

10.2 Estado actual

El rollout está implementado como backend, pero todavía no forma parte de una vista interactiva estable en el dashboard principal. Esto se decidió para evitar introducir una interfaz incompleta en el entregable final. La prioridad inmediata es asegurar que el dashboard base funciona y que el modelo se puede reproducir.

11. Dashboard y estado de integración

11.1 Estado estable actual

El dashboard principal se mantiene en `sprint3/app.py` con cuatro pestañas estables: Dashboard, Series temporales, Recomendación y Alertas.

Durante el Sprint 4 se exploró una ampliación con una quinta pestaña orientada a agronomía y RL. Sin embargo, esta integración provocó problemas de carga en Streamlit. Para proteger la estabilidad del entregable, se revirtió la conexión de la pestaña y se dejó el dashboard principal en un estado funcional.

11.2 Trabajo preparado para el dashboard v2

Aunque la pestaña no está conectada, el backend ya prepara varios elementos que podrán integrarse:

- selector de cultivo;
- selector de zona;
- evaluación de riesgo agronómico;
- recomendación de acción RL;
- calendario de crecimiento;
- requisitos del cultivo;
- métricas de estado del LSTM;
- predicción del siguiente estado;
- comparación de cambios entre estado actual y predicho.

La vista preparada se encuentra en `sprint3/tabs/tab_agronomia.py`. El adaptador para predicciones LSTM está en `sprint3/dashboard_lstm.py`.

11.3 Decisión técnica

La decisión tomada es separar entrega estable de integración experimental:

- el dashboard principal queda estable;
- el backend avanzado queda versionado;
- la integración visual queda preparada, pero pendiente de validación;
- la documentación explica cómo conectar el modelo al frontend en el siguiente paso.

12. Dashboard v2 previsto

12.1 Objetivo de la ampliación

La ampliación prevista del dashboard no consiste simplemente en añadir una pestaña más. El objetivo es que el dashboard pase de ser una herramienta de observabilidad a ser una herramienta de decisión. En la versión actual el usuario puede ver el estado del sistema, inspeccionar series temporales, consultar recomendaciones y revisar alertas. En la versión v2 prevista, además, podrá entender cómo afectan las decisiones de rotación y riego al cultivo y a la energía.




Figura 3. Mapa funcional del dashboard v2 previsto. La nueva vista agronómica conectaría datos a 10 minutos, modelo LSTM, política RL offline y recompensa multiobjetivo.

12.2 Estructura de navegación propuesta

La estructura recomendada para el dashboard final es:

11. **Estado general:** resumen de KPIs energéticos, estado climático, estado de sensores y situación operativa actual.
12. **Series temporales:** visualización histórica de radiación, temperatura, humedad, producción, ángulo y variables derivadas.
13. **Recomendación:** recomendación operativa de ángulo de placas y explicación de la decisión.
14. **Alertas:** detección de valores fuera de rango, riesgos de cultivo y avisos de calidad de datos.
15. **Agronomía y políticas:** vista nueva para seleccionar cultivo y zona, evaluar riesgos, consultar acción RL, simular riego y visualizar rollouts.

12.3 Contenido de la nueva vista agronómica

La pestaña **Agronomía y políticas** debería incluir los siguientes bloques:

- **Selector de cultivo:** permite elegir entre cultivos definidos en la base agronómica, como lechuga, patata o cebolla.
- **Selector de zona:** permite analizar R1, S1 o futuras zonas equivalentes de forma independiente.

- **Estado del cultivo:** muestra humedad, temperatura del suelo, radiación disponible, etapa de crecimiento y rangos favorables.
- **Riesgos agronómicos:** indica déficit hídrico, exceso de agua, estrés térmico, frío o exceso de radiación.
- **Acción recomendada:** muestra la acción elegida por la política RL offline, separando ángulo de placas y decisión de riego.
- **Reward descompuesta:** presenta por separado la componente agrícola, la componente energética y las penalizaciones.
- **Simulación de política:** permite comparar cómo evolucionarían humedad, temperatura, PAR y energía bajo distintas acciones.
- **Calendario del cultivo:** muestra etapa actual, duración estimada y ventana orientativa de cosecha.

12.4 Visualizaciones recomendadas

- **Barras de reward:** una barra para agricultura, otra para energía y otra para penalización.
- **Semáforo agronómico:** estado actual del cultivo con colores para favorable, aviso y crítico.
- **Curva de rollout:** evolución futura simulada de VWC, temperatura del suelo, PAR y producción bajo la política seleccionada.
- **Comparador de políticas:** tabla con varias opciones, como maximizar energía, proteger cultivo, riego conservador o política balanceada.
- **Timeline de riego:** marcas temporales que indiquen cuándo se activaría el riego y con qué dosis.
- **Movimiento de placas:** representación sencilla del ángulo actual y ángulo recomendado.

12.5 Flujo de uso previsto

16. El usuario abre el dashboard y revisa el estado general.
17. Si hay una alerta de humedad, entra en la vista agronómica.
18. Selecciona el cultivo y la zona afectada.
19. El dashboard muestra si el cultivo está fuera de rango y qué variable causa el problema.
20. La política RL propone una acción: cambiar ángulo, activar riego o mantener estado.
21. El usuario consulta la recompensa descompuesta para entender el motivo.
22. El dashboard simula una trayectoria corta y muestra si la acción estabiliza el cultivo.

12.6 Conexión técnica con el backend

La conexión técnica prevista se apoya en módulos ya existentes:

- `sprint3/data_loader.py`: carga datasets, métricas, estado del modelo y ventanas recientes.
- `sprint3/agricultural_rules.py`: calcula rangos, etapas y riesgos por cultivo.
- `sprint3/rl_policy.py`: genera recomendación de acción y recompensa.
- `sprint3/dashboard_lstm.py`: prepara predicciones LSTM para mostrar deltas en dashboard.
- `sprint3/world_model_rollout.py`: permite simular trayectorias futuras bajo una secuencia de acciones.
- `sprint3/tabs/tab_agronomia.py`: contiene una primera versión de la vista agronómica.

12.7 Criterio para integrarlo sin romper el dashboard

Para evitar repetir los problemas de carga detectados, la integración debería hacerse en pasos:

23. Conectar la pestaña sin cargar modelos pesados al inicio.
24. Usar `st.cache_data` y `st.cache_resource` para datasets y modelos.
25. Mostrar primero datos agronómicos estáticos y reglas.
26. Añadir después recomendación RL.
27. Añadir por último predicción LSTM y rollouts.
28. Probar cada paso en navegador antes de añadir el siguiente.

13. Gestión de artefactos y reproducibilidad

13.1 Problema con archivos grandes

Al intentar subir el repositorio a GitHub se detectó que dos archivos CSV superaban o se acercaban a los límites recomendados:

- `sprint3/outputs/master_dataset_world_model.csv`: aproximadamente 98.89 MB.
- `sprint3/outputs/world_model_training_dataset.csv`: aproximadamente 118.19 MB.

GitHub rechaza archivos superiores a 100 MB y recomienda evitar archivos mayores de 50 MB. Por este motivo, estos CSV se eliminaron del commit y se añadieron a `.gitignore`.

13.2 Cómo regenerar los datos

Los compañeros no necesitan recibir esos CSV en Git si el pipeline es reproducible. Los pasos son:

29. Ejecutar el notebook:

```
sprint3/Master_dataset_reg.ipynb
```

30. Generar el dataset de entrenamiento:

```
python sprint3/build_world_model_training_dataset.py
```

31. Entrenar el LSTM si se quieren regenerar los artefactos:

```
python sprint3/train_world_model_lstm.py --epochs 30 --batch-size 512
```

Esta solución mantiene el repositorio ligero y evita depender de Git LFS en esta fase. Si el proyecto continúa y los datasets generados se consideran entregables obligatorios, sería recomendable usar Git LFS, un almacenamiento compartido o un enlace externo versionado.

14. Validación y pruebas

14.1 Pruebas automatizadas

Tras los cambios del Sprint 4 se ejecutó la suite de tests y el resultado fue:

```
94 passed
```

Las pruebas cubren:

- reglas agronómicas;
- política RL;
- pipeline de 10 minutos;
- generación de dataset del modelo del mundo;
- preparación de ventanas LSTM;
- entrenamiento e inferencia LSTM;
- rollout del modelo;
- carga de datos y estado del modelo.

14.2 Validaciones específicas realizadas

Además de los tests, se revisaron puntos concretos:

- corrección de duplicados o colisiones en identificadores de episodio;
- coherencia del número de filas generado por la multiplicación de escenarios de riego;
- separación entre targets aprendidos y variables deterministas;
- capacidad de regenerar datasets grandes localmente;
- estabilidad del dashboard tras revertir la pestaña experimental;
- push correcto del backend sin archivos CSV grandes.

15. Limitaciones actuales

15.1 Datos reales de riego

La mayor limitación sigue siendo la ausencia de datos reales de riego. Toda la parte hídrica del MDP se apoya en simulación. Esto es válido para construir una prueba de concepto, pero no permite validar la política como recomendación real sin datos adicionales.

15.2 Lecturas de humedad cada 6 horas

Las lecturas originales de humedad no capturan bien variaciones rápidas. La resolución de 10 minutos es útil para control, pero se obtiene mediante simulación. Es necesario dejar clara esta diferencia en la presentación final.

15.3 Modelo entrenado sobre dinámica simulada

El LSTM aprende en gran parte una dinámica generada por reglas y parámetros. Por tanto, sus buenos resultados no deben interpretarse como evidencia de precisión física completa. Indican que el modelo aprende bien el entorno simulado.

15.4 Integración visual incompleta

El backend agronómico y RL está preparado, pero la integración completa en el dashboard principal no se ha dejado activada. La decisión fue priorizar estabilidad de la demo. El siguiente paso será integrar la pestaña agronómica de forma incremental y validarla con capturas o pruebas de carga.

15.5 Validación agronómica pendiente

Los rangos de cultivo y penalizaciones son razonables para una demo, pero deberían validarse con fuentes agronómicas o con feedback experto si el proyecto pasa a una fase real.

15.6 Reafirmación del out of scope

Tal y como comentamos en las primeras entregas no recogeríamos datos nuevos, y por este motivo cogemos un subconjunto de los datos que se nos proporcionaron para simular la entrada de datos nuevos.

16. Próximos pasos recomendados

32. **Cerrar dashboard v2 estable:** conectar la pestaña agronómica de forma incremental, probando carga y navegación en Streamlit.
33. **Añadir comparación de políticas:** mostrar en el dashboard la recompensa estimada de varias estrategias de rotación y riego.
34. **Visualizar rollouts:** representar cómo evolucionan humedad, temperatura, PAR y energía bajo una política seleccionada.
35. **Separar claramente datos reales y simulados:** usar etiquetas visuales y documentación para evitar interpretaciones erróneas.
36. **Validar parámetros agronómicos:** contrastar rangos por cultivo con fuentes externas o expertos.

17. Conclusión

El Sprint 4 ha transformado el proyecto desde un dashboard principalmente descriptivo hacia una arquitectura de decisión más completa. Se ha incorporado una formulación de MDP, una simulación de riego y suelo, reglas agronómicas por cultivo, una recompensa multiobjetivo, una política RL offline y un LSTM para aproximar transiciones del sistema.

La principal mejora técnica es que ahora el sistema puede razonar sobre acciones y consecuencias, no solo mostrar datos históricos. La principal precaución es que parte de esa capacidad se basa en simulación debido a la falta de datos reales de riego. Por ello, el resultado debe presentarse como un prototipo avanzado y reproducible de soporte a la decisión, no como un controlador validado en campo.

En términos de entrega, el dashboard estable se mantiene funcional y el backend avanzado queda preparado para integración. Esta separación permite cumplir el objetivo de cierre del Sprint 4 sin comprometer la demo final, dejando además una base clara para continuar el desarrollo.