
Análisis y Optimización Operativa de Sistemas Agrovoltáicos Dinámicos

E01 — Informe de Análisis Exploratorio de Datos

Resultados y análisis del Sprint 1

Organización:	Sostenibilidad y Ciencia
Equipo:	Daniel Álvarez / Chacorocalfarobar
Sprint:	1 de 4 — EDA e insights
Entregable:	E01 — Informe de Resultados del EDA
Fecha:	17 de abril de 2026

ÍNDICE

ÍNDICE	1
1. Introducción	3
2. Inventario de datasets	4
2.1 Datasets de sensores (baja y media frecuencia)	4
2.2 Datasets de precipitación (alta frecuencia)	4
2.3 Consideraciones iniciales sobre los datasets CSV	5
2.3.1 Datasets de precipitación duplicados	5
2.3.2 Redundancia en precipitación acumulada	5
2.3.3 Codificación del tipo de precipitación	6
2.3.4 Temperatura de paneles fotovoltaicos	6
2.3.5 Selección del subconjunto final de datasets	6
3. Auditoría de calidad de datos	8
3.1 Resumen cuantitativo de calidad	8
3.2 Distribución de nulos por columna	8
4. Análisis temporal	10
4.1 Frecuencias de muestreo y cobertura efectiva	10
4.2 Patrones intradiarios	10
4.3 Evolución temporal de variables energéticas y microclimáticas	11
5. Análisis univariante	14
5.1 Variables de tracking (ángulo de rotación)	14
5.2 Irradiancia (GPOA y Albedo)	14
5.3 Temperatura del aire	15
5.4 Temperatura del suelo	15
5.5 VWC (contenido volumétrico de agua del suelo)	15
5.6 ePAR (radiación fotosintéticamente activa)	16
6. Correlaciones y relaciones entre variables	17
6.1 Dataset integrado a 6 horas	17
6.2 Matriz de correlaciones (Spearman)	17
6.3 Correlaciones del tracking con el resto de variables	18
7. Análisis orientado al dominio agrovoltaico	19
7.1 Segmentación por régimen de tracking	19
7.2 Comparativa entre secciones S1 y S2	19
7.3 Umbrales agronómicos del ePAR	20
8. Hipótesis sobre sensores y espacios de investigación	22
8.1 Correlaciones entre trackers: inferencia de grupos físicos	22
8.2 Perfil de exposición lumínica por sensor ePAR	23
8.3 Tabla resumen de hipótesis	23
9. Visión integrada del sistema	24
10. Conclusiones del EDA	25
10.1 Estado de los datos	25
10.2 Variables más relevantes para el proyecto	25
10.3 Insights accionables para el Sprint 2	25

10.4 Riesgos técnicos identificados	25
11. Siguietes pasos (Sprint 2)	27

1. Introducción

Este informe documenta los **resultados** del análisis exploratorio de datos (EDA) realizado durante el Sprint 1 del proyecto *Análisis y Optimización Operativa de Sistemas Agrovoltáicos Dinámicos*. Complementa al entregable E02 (notebook reproducible) proporcionando la narrativa técnica, la interpretación de los resultados y las conclusiones accionables necesarias para orientar el Sprint 2.

El sistema analizado es una instalación agrovoltáica dinámica en la que paneles solares con eje de rotación comparten espacio con un cultivo. La rotación de los paneles afecta simultáneamente a la producción energética y al microclima del cultivo. El objetivo del EDA no es solo describir los datos, sino **sentar las bases analíticas para un modelo de decisión multiobjetivo** que equilibre ambas variables.

2. Inventario de datasets

Se identificaron **16 ficheros CSV** en la carpeta `data/`, agrupados en dos familias según su resolución temporal:

2.1 Datasets de sensores (baja y media frecuencia)

La tabla siguiente resume los ocho datasets principales de sensores que forman el núcleo del análisis.

Tabla 1. Inventario de datasets de sensores

Dataset	KB	Filas	Cols	Inicio	Fin
Temperatura del aire	133,2	1.461	13	12/02/2025	12/02/2026
ePAR	448,7	1.461	25	12/02/2025	12/02/2026
Irradiancia (GPOA)	92,2	1.753	5	12/05/2025	05/10/2025
Temp. paneles FV	126,8	1.753	9	12/05/2025	05/10/2025
Temperatura del suelo	138,6	1.461	15	12/02/2025	12/02/2026
VWC (humedad suelo)	114,2	1.461	15	12/02/2025	12/02/2026
Ángulos de tracking	126,4	1.461	11	12/02/2025	12/02/2026
Velocidad del viento	38,5	1.461	2	12/02/2025	12/02/2026

Los datasets de temperatura del aire, ePAR, temperatura del suelo, VWC, tracking y velocidad del viento cubren un período nominal completo de **365 días** (febrero 2025 – febrero 2026). Los datasets de irradiancia y temperatura de panel tienen una cobertura más corta: **146 días**, desde mayo hasta octubre de 2025, coincidiendo con la temporada de mayor radiación solar.

2.2 Datasets de precipitación (alta frecuencia)

Cinco ficheros adicionales recogen datos de precipitación cada **30 segundos**, alcanzando entre 605.000 y 605.682 filas cada uno. Su tamaño oscila entre 16,7 y 26,2 MB. Para el análisis exploratorio se trabajó con un muestreo de 1:10, reduciendo la carga de memoria a aproximadamente 60.500 filas por fichero.

Observación: cobertura temporal diferenciada

Los datasets energéticos (irradiancia, temperatura de panel) tienen una cobertura temporal inferior (146 días vs. 365) y empiezan tres meses después que el resto. Esto es relevante para el Sprint 2: la modelización multiobjetivo solo podrá realizarse sobre el subconjunto temporal en que todos los datasets se solapan, que corresponde aproximadamente al **período de mayo a octubre de 2025**.




Figura 1. Cobertura temporal por dataset. Los datasets energéticos (irradiancia, temperatura de panel) presentan una ventana más corta, limitada al período estival de 2025.

2.3 Consideraciones iniciales sobre los datasets CSV

Antes de iniciar el análisis exploratorio, se realizó una fase de revisión y validación de los ficheros CSV disponibles con el objetivo de identificar redundancias, inconsistencias y seleccionar el subconjunto óptimo de datos para el análisis.

2.3.1 Datasets de precipitación duplicados

Se detectó que los ficheros:

- Precipitation_data
- Intrensiy_Precipitation

contienen exactamente el mismo contenido, presentando únicamente diferencias en el nombre del archivo.

Tras la comparación directa de ambos datasets, se comprobó que:

- Coinciden en número de filas y columnas
- Presentan los mismos valores en todas las observaciones

Decisión:

Se excluye Intrensiy_Precipitation y se mantiene Precipitation_data como fuente válida.

2.3.2 Redundancia en precipitación acumulada

Se analizaron los ficheros:

- Precipitation_quantity (Total Difference cumulative sum)
- Precipitation (Total Difference cumulative sum)

Ambos datasets contienen la misma información en el intervalo común, pero:

- Comparten el mismo inicio temporal
- Uno de ellos incluye registros adicionales más recientes

Decisión:

Se selecciona Precipitation (Total Difference cumulative sum) por presentar mayor cobertura temporal.

2.3.3 Codificación del tipo de precipitación

Se identificaron dos versiones del dataset de tipo de precipitación:

- Codificación simple
- Codificación estándar WMO (wawa)

El análisis conjunto muestra:

- Alta concordancia entre ambas fuentes en la mayoría de registros
- Predominio de valores sin precipitación
- Discrepancias puntuales en la clasificación de eventos

Interpretación:

Ambos datasets son coherentes, pero presentan diferencias de granularidad en la codificación.

Decisión:

Se prioriza la versión más estandarizada (WMO) para facilitar futuras interpretaciones meteorológicas.

2.3.4 Temperatura de paneles fotovoltaicos

Se compararon los datasets:

- PV_panel_temperatures
- PV_panel_temperatures_Section_S1

Se observa que:

- Cubren el mismo rango temporal (mayo–octubre 2025)
- Presentan diferente resolución temporal (2h vs 3h)
- Uno incluye ambas secciones (S1 y S2), mientras el otro solo S1

Decisión:

Se selecciona PV_panel_temperatures al ofrecer:

- Mayor resolución temporal
- Cobertura completa de ambas secciones

2.3.5 Selección del subconjunto final de datasets

Como resultado de esta fase de depuración, se define el subconjunto de datos que se utilizará en el análisis:

- Temperatura del aire
- ePAR
- Irradiancia
- Temperatura de paneles
- Temperatura del suelo

- Humedad del suelo (VWC)
- Tracking
- Velocidad del viento
- Precipitación acumulada

Esta selección garantiza:

- Eliminación de redundancias
- Máxima cobertura temporal disponible
- Consistencia entre variables clave del sistema

3. Auditoría de calidad de datos

3.1 Resumen cuantitativo de calidad

La tabla siguiente recoge las principales métricas de calidad por dataset.

Tabla 2. Resumen de calidad por dataset

Dataset	Filas	Cols	Nulos %	Dupl .	Freq.	Const./Pr ob.
air_temp	1.461	13	37,4	0	6 h	—
epar	1.461	25	37,1	0	6 h	—
irradiance	1.753	5	29,6	0	2 h	—
pv_temp	1.753	9	29,6	0	2 h	—
soil_temp	1.461	15	44,7	0	6 h	—
soil_vwc	1.461	15	46,6	0	6 h	—
tracking	1.461	11	30,5	0	6 h	—
wind_speed	1.461	2	45,4	0	6 h	—
precip_type	60.501	2	100,0	0	5 min	Col. constante
precip_cumsu m	60.502	2	0,0	0	5 min	—

Ningún dataset presenta filas duplicadas, lo que indica que el sistema de adquisición no genera registros redundantes. Sin embargo, el porcentaje de nulos es significativo en todos los datasets de sensores:

- **Nulos moderados (29–37%):** irradiancia, temperatura de panel, ePAR, temperatura del aire, tracking. Este nivel es consistente con el hecho de que el período de datos válidos comenzó en junio de 2025, mientras los timestamps vacíos se extienden desde febrero de 2025.
- **Nulos elevados (44–46%):** temperatura del suelo, VWC y velocidad del viento superan el 44% de valores nulos, lo que sitúa el período efectivo de datos útiles en alrededor de **8 meses** de los 12 nominales.
- **Columna constante (100% nulos):** el dataset `precip_type` presenta la columna `Precipitation Type` íntegramente vacía durante el subconjunto analizado, lo que la invalida para cualquier análisis.

3.2 Distribución de nulos por columna

La figura siguiente muestra el porcentaje de nulos columna a columna. La zona **R1** (sensores R1d40, R1d41, R1d42, etc.), concentra un poco más de valores nulos en alguna variable. Esto contrasta con las zonas S1 y S2, donde los nulos son más uniformes y reflejan únicamente el período de inactividad inicial.



Figura 2. Porcentaje de nulos por columna y dataset. En rojo: columnas con más del 80% de nulos. Los sensores de la zona R1 aparecen sistemáticamente en rojo en todos los datasets.

4. Análisis temporal

4.1 Frecuencias de muestreo y cobertura efectiva

La tabla siguiente resume las características temporales de cada dataset.

Tabla 3. Resumen temporal por dataset

Dataset	Inicio	Fin	Días	Freq.	Huecos >24h
air_temp	12/02/2025	12/02/2026	365	6 h	0
epar	12/02/2025	12/02/2026	365	6 h	0
irradiance	12/05/2025	05/10/2025	146	2 h	0
pv_temp	12/05/2025	05/10/2025	146	2 h	0
soil_temp	12/02/2025	12/02/2026	365	6 h	0
soil_vwc	12/02/2025	12/02/2026	365	6 h	0
tracking	12/02/2025	12/02/2026	365	6 h	0
wind_speed	12/02/2025	12/02/2026	365	6 h	0
wind_dir	12/02/2025	12/02/2026	365	12 h	0
precip_type	16/06/2025	12/02/2026	240	5 min	3
precip_cumsu m	16/06/2025	12/02/2026	240	5 min	3

Los hallazgos más relevantes son:

- **Dos grupos de frecuencia claros:** los datasets de irradiancia y temperatura de panel tienen resolución de **2 horas**, mientras el resto de sensores trabajan a **6 horas**. Esta heterogeneidad requiere resampleo temporal antes de integrar los datasets para la modelización.
- **Sin huecos mayores de 24 horas** en ninguno de los datasets de baja/media frecuencia. El hueco máximo observado es de 7 horas, consistente con un único intervalo perdido en la cadencia de 6 horas.
- **Varios huecos mayores de 24 horas en precipitación:** se detectaron varias interrupciones superiores a un día, con un hueco máximo de 3 días y 3 horas. Esto indica que el pluviómetro de alta frecuencia no registra en continuo sino durante eventos de lluvia o en períodos de operación definidos.
- **Período efectivo de solapamiento:** todos los datasets de sensores tienen datos válidos simultáneamente durante el período **junio – octubre de 2025** (aproximadamente). Este es el período útil para el dataset integrado del Sprint 2.

4.2 Patrones intradiarios

Los perfiles intradiarios (mediana por hora del día) revelan comportamientos físicamente coherentes con la dinámica de un sistema agrovoltaico.




Figura 3. Perfiles intradiarios de cuatro variables clave: GPOA (irradiancia en plano de panel), ángulo de tracking, ePAR bajo el dosel y temperatura del suelo. La banda sombreada representa el rango intercuartílico.

- **GPOA:** curva campaniforme con máximo al mediodía solar. El valor máximo registrado es de $1001 W/m^2$ en S1 y $998 W/m^2$ en S2, consistentes con la irradiancia máxima esperable en condiciones de cielo despejado en la latitud de la instalación.
- **Ángulo de tracking:** el perfil muestra claramente el seguimiento solar: ángulos negativos (hacia el este) por la mañana, cruce por cero al mediodía y ángulos positivos (hacia el oeste) por la tarde. Las transiciones abruptas corresponden a la puesta en posición de stow al final del día.
- **ePAR bajo el dosel:** el máximo de ePAR bajo los paneles no coincide exactamente con el máximo de GPOA. El desfase temporal observable sugiere un **efecto de sombreado asimétrico**: la cantidad de luz que llega al cultivo depende no solo de la intensidad de la radiación solar sino de la posición angular del panel respecto al sol.
- **Temperatura del suelo:** respuesta claramente retardada respecto a la irradiancia. El máximo de temperatura del suelo se alcanza varias horas después del máximo solar, lo que confirma la inercia térmica del suelo como factor a modelizar.

4.3 Evolución temporal de variables energéticas y microclimáticas




Figura 4. Evolución temporal de las variables energéticas: ángulos de los trackers M01–M10, irradiancia GPOA en S1 y S2, y temperatura de paneles FV.




Figura 5. Evolución temporal de las variables microclimáticas: temperatura del aire, temperatura del suelo, VWC y ePAR fotosintético.

La evolución temporal de las variables energéticas permite observar tres patrones destacables:

1. **Comportamiento diferenciado entre trackers:** los trackers Mo1, Mo3, Mo7 y Mo9 siguen patrones de ángulo similares entre sí. En cambio, Mo2, Mo6 y M10 muestran una línea prácticamente plana en torno a $50,6^\circ$, tanto de día como de noche. Este valor constante es incompatible con el funcionamiento normal de un seguidor solar.
2. **Temperatura de panel extrema en S2 T1:** el sensor S2 T1 registra un máximo de 111°C , muy por encima de los valores típicos de los demás sensores de panel (máximos en torno a $50\text{--}53^\circ\text{C}$).
3. **Irradiancia simétrica entre S1 y S2:** los valores de GPOA entre las dos secciones son muy similares (medias de $326,4$ y $326,6\text{ W/m}^2$ respectivamente). Las diferencias entre secciones en el microclima no pueden atribuirse a diferencias en la exposición solar bruta.

5. Análisis univariante

5.1 Variables de tracking (ángulo de rotación)

Tabla 4. Estadísticos descriptivos de los trackers activos

Tracker	N	Media	Std	Min	Q1	Q3	Max
Mo1	1.016	0,35°	19,13°	-32,3°	-10,3°	15,8°	50,6°
Mo3	1.016	0,37°	19,14°	-32,3°	-10,3°	15,9°	50,6°
Mo5	1.016	4,60°	23,13°	-32,3°	-2,5°	21,1°	53,5°
Mo7	1.016	4,60°	23,13°	-32,3°	-2,5°	21,1°	53,5°
Mo9	1.016	0,35°	19,14°	-32,3°	-10,3°	15,9°	50,6°

La media de ángulo de todos los trackers es próxima a 0° , coherente con una distribución simétrica entre posiciones de mañana (negativas) y tarde (positivas). La desviación típica de Mo5 y Mo7 es notablemente mayor ($\sim 23^\circ$) frente a Mo1, Mo3 y Mo9 ($\sim 19^\circ$). El valor máximo de $50,6^\circ$ aparece repetidamente en todos los trackers y corresponde a la posición de stow.




Figura 6. Distribución del ángulo de los trackers Mo1, Mo3 y Mo5. Se aprecian tres modas: posición matutina negativa, posición cercana a horizontal y posición de stow ($\sim 50^\circ$).

5.2 Irradiancia (GPOA y Albedo)

Tabla 5. Estadísticos descriptivos de irradiancia

Variable	N	Media	Std	Min	Max	Nulos %
GPOA S1	1.234	326,4 W/m ²	338,4 W/m ²	-2,93 W/m ²	1032 W/m ²	29,6
GPOA S2	1.233	326,6 W/m ²	337,0 W/m ²	-1,58 W/m ²	1026 W/m ²	29,6
Albedo S1	1.234	38,9 W/m ²	44,7 W/m ²	-6,34 W/m ²	167 W/m ²	29,6
Albedo S2	1.233	37,1 W/m ²	43,3 W/m ²	-1,65 W/m ²	144 W/m ²	29,6

La distribución del GPOA es **bimodal**: un pico en torno a 0 W/m^2 (períodos nocturnos) y un pico diurno que se extiende hasta los $\sim 1.000 \text{ W/m}^2$. Se detectan valores **ligeramente negativos** tanto en GPOA como en Albedo, que son ruido instrumental esperado en condiciones de noche, no outliers reales.




Figura 7. Distribución de GPOA y Albedo en S1 y S2. Se aprecia la distribución bimodal característica de variables con ciclo diario marcado.

5.3 Temperatura del aire

Tabla 6. Estadísticos descriptivos de temperatura del aire

Sensor	N	Media (°C)	Std	Min	Max
WS100 (exterior)	940	17,28	7,25	0,57	31,5
S1 centro	938	18,33	7,31	2,05	33,6
S1 este	938	18,46	7,27	2,19	33,4
S2 este	938	18,13	7,22	1,94	32,4

La temperatura media del aire exterior (WS100) es de 17,28 °C, mientras los sensores bajo el dosel (S1 y S2) registran consistentemente valores entre **1 y 1,2 °C más altos** en promedio. Esta diferencia sistemática puede interpretarse como un **efecto de microclima**: el espacio bajo los paneles presenta una temperatura media ligeramente más elevada, posiblemente por reducción de la convección o por acumulación de calor bajo la estructura metálica.

5.4 Temperatura del suelo

Tabla 7. Estadísticos descriptivos de temperatura del suelo

Sensor	N	Media (°C)	Std	Min	Max
S1d13	899	18,60	7,42	5,43	34,2
S1d14	899	18,46	7,56	4,34	34,8
S2d32	899	18,64	7,49	4,53	32,5
S2d33	899	18,68	7,44	5,27	34,0

La temperatura del suelo es muy homogénea entre sensores (diferencia de medias inferior a 0,22 °C), lo que sugiere condiciones del sustrato similares en S1 y S2. No se detectaron outliers estadísticos.

5.5 VWC (contenido volumétrico de agua del suelo)

Tabla 8. Estadísticos descriptivos del VWC

Sensor	N	Media (%)	Std	Min	Max	Outliers
S1d13	860	25,52	5,83	11,8	38,8	0 (0,0%)
S1d14	860	26,73	7,25	9,01	40,6	0 (0,0%)
S2d32	860	21,02	5,59	7,97	39,5	9 (1,0%)
S2d33	860	24,42	6,67	9,63	39,9	0 (0,0%)

El VWC presenta la diferencia más notable entre secciones de todo el análisis univariante. **S1 presenta una humedad media 4,5 puntos porcentuales superior a S2d32** (25,52% vs. 21,02%). Las causas pueden ser: textura de suelo diferente, profundidad de sensor diferente, estrategia de riego diferenciada o efecto de la sombra del panel sobre la evapotranspiración.

5.6 ePAR (radiación fotosintéticamente activa)

Tabla 9. Estadísticos descriptivos del ePAR

Sensor	N	Media ($\mu\text{mol}/\text{m}^2/\text{s}$)	Std	Min	Max	Outliers
S1d19	938	207,0	356,3	-0,05	2288	49 (5,2%)
S1d20	938	280,9	396,2	-0,03	2351	6 (0,6%)
S2d36	938	209,0	337,8	-0,02	2332	38 (4,1%)
S2d37	938	224,9	342,4	-0,04	1840	8 (0,9%)

El ePAR es la variable con mayor variabilidad relativa: la desviación típica supera en todos los casos al valor medio. Los sensores S1d19 y S2d36 presentan un **5,2% y 4,1% de outliers** respectivamente (por método $\text{IQR} \times 3$), lo que sugiere la presencia de lecturas extremas que pueden corresponder a reflexiones directas o a condiciones de cielo despejado con el panel en posición óptima.




Figura 8. Distribución del ePAR en los cuatro sensores seleccionados. La fuerte asimetría positiva refleja la combinación de horas nocturnas ($\text{ePAR} \approx 0$) y picos diurnos de alta irradiancia.

Insight: ePAR bajo el dosel muy inferior al exterior

Los valores de ePAR registrados en los sensores bajo el dosel (máximos de 1840–2351 $\mu\text{mol}/\text{m}^2/\text{s}$) son similares a los valores de referencia exterior para días despejados (~ 2000 $\mu\text{mol}/\text{m}^2/\text{s}$). Sin embargo, los valores *medios* son notablemente inferiores (~ 207 – 281 $\mu\text{mol}/\text{m}^2/\text{s}$), lo que refleja que la posición del panel reduce significativamente la irradiancia PAR que llega al cultivo en la mayor parte de las horas del día. Este efecto de sombreado es el mecanismo físico central del sistema y la variable crítica para el modelo de rotación.

6. Correlaciones y relaciones entre variables

6.1 Dataset integrado a 6 horas

Para el análisis de correlaciones se construyó un dataset integrado resampleando todos los datasets a resolución de **6 horas** (frecuencia común de los sensores de campo). El dataset resultante contiene **1.462 timesteps** × **29 variables**, cubriendo el período completo de febrero 2025 a febrero 2026.

El porcentaje de nulos en el dataset integrado varía entre el 30,5% (variables de tracking) y el 71,5% (irradiancia y temperatura de panel), lo que confirma que el subconjunto con datos completos en todas las variables se concentra en el período estival.

6.2 Matriz de correlaciones (Spearman)

Se utilizó el coeficiente de correlación de Spearman en lugar de Pearson, dado que las relaciones entre la rotación de paneles y las variables microclimáticas son esperablemente no lineales (efectos de umbral, sombreo asimétrico, saturación lumínica).




Figura 9. Matriz de correlaciones de Spearman del dataset integrado a 6 horas. Verde: correlación positiva. Rojo: correlación negativa. Solo se muestra el triángulo inferior.

Los patrones más relevantes de la matriz son:

- **Bloque de trackers:** los trackers activos (M01, M03, M05, M07, M09) presentan correlaciones muy altas entre sí ($r > 0,95$). La casi-colinealidad indica que **un único tracker representativo** (p.ej. M01) puede ser suficiente como feature en el modelo.

- **Bloque energético:** GPOA_S1 y GPOA_S2 tienen una correlación de Spearman superior a 0,99, confirmando la simetría de exposición solar entre secciones. Albedo S1 y S2 también presentan alta correlación con GPOA ($r \approx 0,95$).
- **Temperaturas:** temperatura del aire, temperatura del suelo y temperatura de panel forman un bloque de alta correlación ($r > 0,90$), respondiendo todos a la misma forzante solar.
- **Tracking vs. microclima:** la correlación de Spearman entre el ángulo de tracking y el ePAR es positiva pero moderada, lo que confirma la no linealidad de la relación.
- **VWC:** presenta correlaciones débiles con el resto de variables ($|r| < 0,3$), coherente con su dinámica temporal más lenta y su dependencia de la precipitación.

6.3 Correlaciones del tracking con el resto de variables




Figura 10. Correlaciones de Spearman de todas las variables con el tracker M01 de referencia. Las barras verdes indican correlación positiva y las rojas negativa.

Las correlaciones más fuertes con el ángulo de tracking son con las **temperaturas de panel** (r positivo moderado-alto): un ángulo más perpendicular al sol implica más captación de radiación y mayor temperatura de la celda. La correlación con ePAR bajo el dosel es la más relevante para el proyecto: valores moderados y con dependencia no lineal.

7. Análisis orientado al dominio agrovoltaico

7.1 Segmentación por régimen de tracking

Cada timestep del dataset integrado se clasificó en uno de cuatro regímenes operativos según el ángulo del tracker Mo1:

- **STOW** ($\sim 50,6^\circ$, tolerancia $\pm 0,5^\circ$): posición de aparcamiento/stow.
- **HORIZONTAL** ($\sim 0^\circ$): panel en posición plana o cercana.
- **TRACKING_AM** (ángulo negativo): seguimiento solar matutino.
- **TRACKING_PM** (ángulo positivo): seguimiento solar vespertino.




Figura 12. Distribución de las variables clave (GPOA, ePAR, temperatura del aire, temperatura del suelo y VWC) segmentada por régimen de tracking.

Los resultados de la segmentación son clave para el proyecto:

- **La posición STOW es el régimen más perjudicial para el cultivo:** el ePAR bajo el dosel durante STOW es significativamente inferior al de los regímenes de tracking activo, ya que el panel a $\sim 50^\circ$ bloquea una fracción mayor de la luz difusa e incidente.
- **GPOA es máximo en TRACKING_AM y TRACKING_PM**, como era de esperar, y mínimo en STOW (que ocurre principalmente de noche o en condiciones de viento fuerte).
- **La temperatura del aire y del suelo no difieren significativamente entre regímenes**, lo que confirma que la temperatura responde más a la estación del año y a la hora del día que al ángulo concreto del panel.
- **El VWC no muestra diferencias significativas entre regímenes**, consistente con su dinámica temporal de días, muy superior al ciclo de rotación horario del panel.

7.2 Comparativa entre secciones S1 y S2




Figura 13. Comparativa de GPOA, ePAR, temperatura del suelo y VWC entre secciones S1 y S2. La diferencia de medianas S2-S1 se indica en el eje horizontal.

Las diferencias más relevantes entre secciones son:

- **GPOA:** prácticamente idéntico entre S1 y S2 (Δ mediana $< 5 \text{ W/m}^2$), confirmando que ambas secciones reciben la misma irradiancia solar bruta.
- **ePAR:** diferencia moderada entre sensores individuales. La variabilidad intra-sección es comparable a la variabilidad inter-sección, lo que sugiere que la posición del sensor relativa al panel puede ser más determinante que la sección en sí.
- **Temperatura del suelo:** diferencias mínimas entre S1 y S2 ($< 0,5 \text{ }^\circ\text{C}$ en medianas).
- **VWC: diferencia sistemática y consistente:** S1 presenta una humedad media del suelo de 25–27% frente al 21–24% de S2. Esta diferencia de $\sim 4,5$ puntos porcentuales es estadísticamente relevante y debe ser tomada en cuenta en el modelo.

Riesgo: diferencia de VWC entre secciones

La diferencia sistemática de VWC entre S1 y S2 podría sesgar el modelo si no se incluye una variable indicadora de sección o si se trata a ambas secciones como intercambiables. Se recomienda confirmar con el equipo técnico si existe una causa conocida (diferente tipo de suelo, profundidad de sensor, gestión hídrica) o si la diferencia es un artefacto de calibración de los sensores.

7.3 Umbrales agronómicos del ePAR




Figura 15. Distribución del ePAR en el sensor S1d19 con los tres umbrales agronómicos de referencia superpuestos: punto de compensación lumínica ($20 \text{ } \mu\text{mol/m}^2/\text{s}$), fotosíntesis activa baja ($200 \text{ } \mu\text{mol/m}^2/\text{s}$) y rango óptimo para cultivos C3 ($600 \text{ } \mu\text{mol/m}^2/\text{s}$).

El análisis de umbrales agronómicos para el sensor S1d19 revela la siguiente distribución:

- **Por debajo del punto de compensación ($< 20 \text{ } \mu\text{mol/m}^2/\text{s}$):** incluye todos los períodos nocturnos y parte de los períodos de mayor sombreado. Es el rango en que la planta no realiza fotosíntesis neta.
- **Fotosíntesis activa baja ($200\text{--}600 \text{ } \mu\text{mol/m}^2/\text{s}$):** rango subóptimo pero productivo para la mayoría de cultivos C3.
- **Rango óptimo ($> 600 \text{ } \mu\text{mol/m}^2/\text{s}$):** representa los períodos de máxima actividad fotosintética bajo condiciones de baja obstaculización por el panel.

Insight: definición de umbrales para el modelo de rotación

El análisis de umbrales proporciona la base para definir **restricciones operativas** en el modelo de rotación del Sprint 2. Una regla candidata sería: «La posición del panel no debe reducir el ePAR bajo el dosel por debajo de $X \text{ } \mu\text{mol/m}^2/\text{s}$ durante más de N horas

consecutivas en el período entre amanecer y puesta de sol.» Los valores de X y N deben validarse con el especialista agrícola del proyecto en función del tipo de cultivo.

8. Hipótesis sobre sensores y espacios de investigación

8.1 Correlaciones entre trackers: inferencia de grupos físicos





Figura 16. Matriz de correlaciones de Spearman entre los trackers M01–M10 y varianza del ángulo por tracker. Los trackers con varianza próxima a cero presentan posición fija.



El análisis de correlaciones entre trackers revela dos grupos bien diferenciados:

- **Grupo 1 (Mo1, Mo3, Mo4, Mo8, Mo9)**
- **Grupo 1 (Mo2, Mo5, Mo6, Mo7, M10)**

No sabemos qué grupo pertenece a cada zona (S1, S2). Esta duda ya ha sido transmitida al cliente y se tendrá en cuenta en las futuras etapas del proyecto.

8.2 Perfil de exposición lumínica por sensor ePAR




Figura 17. Mediana de ePAR por sensor (izquierda) y correlaciones entre sensores (derecha). Los sensores con mayor mediana reciben más luz en promedio y están más expuestos.

El perfil de medianas de ePAR por sensor revela diferencias de exposición entre posiciones dentro de la misma sección. Los sensores *cal_out* (señal calibrada exterior) tienen medianas sistemáticamente superiores a los sensores *immersed* (sumergidos bajo el dosel), coherente con su posición relativa. Las correlaciones entre sensores de la misma sección son altas ($r > 0,90$).

8.3 Tabla resumen de hipótesis

Tabla 10. Hipótesis propuestas sobre la estructura espacial de la instalación

Elemento	Hipótesis	Evidencia
R1	Zona de referencia sin cobertura de paneles, no instrumentada operativamente durante el período analizado	>95% nulos en todos los sensores R1
S1	Sección experimental 1 con trackers Mo1–Mo5 (activos)	Datos válidos en S1d10–S1d21; alta correlación ePAR con trackers impares
S2	Sección experimental 2 con trackers Mo6–M10, posiblemente con estrategia diferente	Datos válidos en S2d30–S2d37; VWC sistemáticamente inferior
Mo2, Mo6, M10	Trackers con posible fallo mecánico o posición de stow permanente	Varianza de ángulo próxima a 0; valor constante $\sim 50,6^\circ$
WS100	Estación meteorológica exterior de referencia sin influencia de la estructura	Prefijo diferenciado; temperaturas ligeramente inferiores a sensores bajo dosel

9. Visión integrada del sistema




Figura 18. Evolución integrada de las cuatro variables clave del sistema durante el período completo: ángulo de tracking MO1, GPOA S1, ePAR S1 y VWC S1.

La lectura conjunta de las cuatro series clave permite observar la dinámica global del sistema. El ángulo de tracking oscila diariamente entre $-32,3^\circ$ y $50,6^\circ$. El GPOA refleja tanto el ciclo diario como la variación estacional. El ePAR bajo el dosel sigue al GPOA con menor amplitud, mostrando la atenuación ejercida por los paneles. El VWC evoluciona en escala de días-semanas, con pulsos de recarga asociados a eventos de precipitación.

La co-visualización de estas series es el punto de partida para identificar qué combinaciones de ángulo, irradiancia y estado hídrico del suelo son favorables o desfavorables para el cultivo, base del **índice combinado Energía–Cultivo** que se desarrollará en el Sprint 2.

10. Conclusiones del EDA

10.1 Estado de los datos

Los datos disponibles cubren nominalmente un año completo para la mayoría de sensores, pero el período con datos válidos (no nulos) se limita a aproximadamente **8 meses**, con la ventana de máximo solapamiento entre datasets concentrada en **junio–octubre de 2025**. La calidad es buena en ausencia de duplicados y con una regularidad temporal alta (sin huecos mayores de 7 horas en los datasets de sensores). Los problemas principales son: zona R1 no operativa, trackers anómalos y unidades embebidas en strings que requieren limpieza previa.

10.2 Variables más relevantes para el proyecto

Tabla 11. Variables prioritarias para el Sprint 2

Categoría	Variables	Justificación
Control / Actuación	track_M01 (representativo)	Variable de decisión del modelo de rotación
Energía	GPOA_S1, GPOA_S2, Albedo_S1	Producción potencial del sistema FV
Microclima crítico	ePAR_S1d19, ePAR_S2d36	Luz disponible para el cultivo; umbral fotosintético
Microclima suelo	VWC_S1d13, VWC_S2d32	Estado hídrico; diferencia sistemática S1–S2
Temperatura	Tsoil_S1d13, Tair_WS	Estrés térmico; referencia exterior
Meteorología	wind_speed, precip_cumsum	Variables exógenas para condiciones de stow y riego

10.3 Insights accionables para el Sprint 2

- 1. La posición de stow (50,6°) degrada el microclima del cultivo.** Las reglas de rotación deben minimizar el tiempo en stow durante las horas de luz, reservándola solo para condiciones de viento fuerte o criterios de seguridad. Cuantificar cuántas horas de stow diurno son aceptables es la primera restricción a definir en el Sprint 2.
- 2. El lag térmico del suelo (6–12h) debe incorporarse como feature.** El modelo no puede tomar decisiones de rotación basadas solo en la irradiancia instantánea; debe considerar la irradiancia acumulada de las horas previas para predecir el efecto sobre la temperatura del suelo.
- 3. S1 y S2 requieren tratamiento diferenciado.** La diferencia sistemática de 4,5 puntos porcentuales en VWC entre secciones implica que un modelo único para ambas secciones puede tener un sesgo. Se recomienda incluir una variable indicadora de sección o entrenar modelos separados.
- 4. El índice combinado Energía–Cultivo debe incorporar GPOA y ePAR con ponderación a definir.** Una propuesta inicial: $IEC = \alpha \cdot GPOA + (1-\alpha) \cdot ePAR_{norm}$, donde α representa la ponderación energía–cultivo y $ePAR_{norm}$ es el ePAR bajo el dosel normalizado por el ePAR exterior de referencia.

10.4 Riesgos técnicos identificados

Tabla 12. Riesgos técnicos derivados del EDA

Riesgo	Nivel	Mitigación propuesta
Zona R1 sin datos	Alto	Confirmar con cliente; buscar datos en otros períodos
Trackers Mo2/Mo6/M10 anómalos	Medio	Verificación técnica; excluir del modelo hasta confirmación
Cobertura estival únicamente	Medio	Explicitar la limitación de generalización estacional
Sensor S2 T1 con valor extremo (111 °C)	Medio	Excluir o marcar como outlier; verificar calibración
Sin información del tipo de cultivo	Medio	Solicitar al cliente; usar umbrales conservadores
Sin grupo de control R1	Alto	Usar WS100 como referencia exterior parcial
Diferencia VWC S1–S2 no explicada	Bajo-Medio	Confirmar con equipo técnico la causa

11. Siguientes pasos (Sprint 2)

- S2-1. **Validación técnica:** confirmar con el equipo de la planta el estado de los trackers Mo2, Mo6 y M10; el motivo de inactividad de la zona R1; el tipo de cultivo y los umbrales agronómicos aplicables.
- S2-2. **Pipeline de limpieza definitivo:** formalizar las funciones `strip_unit`, `load_csv` y `resample_to_6h` como módulo reusable; documentarlas y versionar en el repositorio.
- S2-3. **Feature engineering:** añadir variables derivadas al dataset integrado: hora del día, ángulo solar teórico calculado, lag features de temperatura del suelo (6h, 12h), diferencial S1–S2 de VWC, indicador de régimen de tracking.
- S2-4. **Definición del target:** proponer y validar con el equipo la formulación del índice combinado Energía–Cultivo (IEC) que actuará como variable objetivo del modelo multiobjetivo.
- S2-5. **Modelización:** entrenar al menos dos enfoques (árbol de decisión para interpretabilidad, regresión regularizada para generalización) usando el período de solapamiento completo como conjunto de entrenamiento.
- S2-6. **Validación agronómica:** someter las reglas de rotación propuestas por el modelo a revisión del especialista agrícola del equipo antes de incorporarlas al dashboard.